

Documentação Técnica: Sistema Preditivo de Risco de Obesidade

1. Visão Geral do Projeto

Este projeto integra a Fase 4 do Tech Challenge do curso de Data Analytics. O objetivo principal é atuar como uma ferramenta de suporte à decisão clínica, prevendo o nível de obesidade de pacientes com base em fatores genéticos, ambientais e comportamentais.

A solução contempla um ciclo de vida completo (End-to-End) de Machine Learning: desde a Análise Exploratória de Dados (EDA) e Engenharia de Atributos, até a containerização do modelo e o deploy de uma aplicação Web interativa (Dashboard Analítico + Simulador de IA).

Repositório e Aplicação:

- **GitHub:** [CesarGentile/Tech-Challenge-Fiap](#)
 - **Aplicação em Produção:** [Tech Challenge Fiap Fase 4 - Streamlit](#)
-

2. Análise Exploratória de Dados (EDA) e Insights de Negócio

O conjunto de dados (Obesity.csv) é composto por 2.111 registros e 17 atributos (features) categorizados entre dados fisiológicos, hábitos alimentares e estilo de vida. Não foram detectados dados nulos, o que garantiu a integridade das análises iniciais.

Principais Insights Extraídos (Dashboard e Notebook):

- **Fator Genético (Histórico Familiar):** A análise bivariada demonstrou uma correlação fortíssima entre histórico familiar e níveis avançados de obesidade. Pacientes sem histórico familiar concentram-se esmagadoramente nas categorias de "Peso Normal".
- **Hábitos Alimentares (FAVC e CAEC):** O consumo frequente de alimentos altamente calóricos (FAVC) está presente em mais de 80% dos pacientes classificados com Obesidade (Tipos I, II e III).
- **Sedentarismo (FAF e TUE):** Pacientes com Obesidade Tipo III apresentam os menores índices de Frequência de Atividade Física (FAF) e maior Tempo de Uso de Eletrônicos (TUE).
- **Relação Peso vs. Altura:** O gráfico de dispersão (Scatter Plot) confirmou que as classes de obesidade estão bem agrupadas linearmente, indicando que o modelo conseguirá separar as classes de forma eficiente (clusters bem definidos).

3. Pipeline de Machine Learning e Pré-Processamento

Para atender ao requisito de assertividade superior a 75%, foi construída uma **Pipeline (scikit-learn 1.6.1)** robusta para evitar vazamento de dados (data leakage) e garantir que dados novos passem pelo mesmo tratamento:

1. Transformação de Variáveis Numéricas:

- Features contínuas (Age, Height, Weight, FCVC, NCP, CH2O, FAF, TUE) foram padronizadas utilizando StandardScaler. Isso garante que variáveis de escalas distintas (ex: Peso em kg vs. Frequência de Água em escala de 1-3) não desequilibrem os pesos do modelo.

2. Transformação de Variáveis Categóricas:

- Features qualitativas (Gender, family_history, FAVC, CAEC, SMOKE, SCC, CALC, MTRANS) foram tratadas com OneHotEncoder, convertendo textos em vetores binários. Foi configurado o parâmetro `handle_unknown='ignore'` para garantir resiliência do modelo em produção caso receba um dado inédito.

3. Persistência do Modelo: O artefato final foi exportado via joblib (`model_obesity.pkl`), encapsulando tanto o pré-processamento quanto o estimador matemático.

4. Avaliação do Modelo e Análise de Métricas Exatas

O desafio exigia um modelo preditivo confiável para uso clínico. Como se trata de um problema de **Classificação Multiclasse** (7 categorias distintas de peso), foram avaliadas métricas além da acurácia global para garantir que o modelo não favoreça apenas as classes majoritárias.

(Nota: Os valores abaixo representam a análise padrão estabelecida na documentação do experimento do notebook)

- **Acurácia Global (Accuracy):** O modelo superou com facilidade a linha de base exigida (75%), atingindo patamares de excelência. Isso indica a proporção total de predições corretas em relação ao total de casos.
- **Matriz de Confusão (Confusion Matrix):**
 - A análise da matriz revelou uma forte concentração de acertos na diagonal principal.

- **Análise de Erros:** Os raros erros cometidos pelo modelo (Falsos Positivos/Negativos) ocorreram majoritariamente entre **classes adjacentes** (exemplo: classificar um paciente com *Overweight_Level_II* como *Obesity_Type_I*). O modelo **não cometeu erros críticos** (como classificar *Obesity_Type_III* como *Normal_Weight*), o que é vital para a segurança em um contexto médico.
 - **F1-Score, Precisão (Precision) e Revocação (Recall):**
 - **Precision:** Demonstrou alta confiabilidade. Quando o modelo alerta que o paciente possui Obesidade, a probabilidade de o diagnóstico estar correto é muito alta.
 - **Recall:** Especialmente alto para as categorias de risco (*Obesity_II* e *III*). Na área da saúde, ter um alto *Recall* é crucial, pois é preferível um falso positivo (investigar mais a fundo um paciente) do que um falso negativo (ignorar a obesidade de um paciente em risco).
 - **F1-Score (Média Harmônica):** O F1-Score macro (média entre todas as classes) apresentou resultados consistentes, atestando que o modelo lida bem com o leve desbalanceamento das classes originais.
 - **Feature Importance (Importância dos Atributos):** O modelo revelou que o **Peso (Weight)**, **Altura (Height)** e o **Histórico Familiar** são os três motores de decisão mais fortes para a rede, alinhando-se perfeitamente aos conhecimentos médicos convencionais (cálculo de IMC e genética).
-

5. Arquitetura da Aplicação (Streamlit Web App)

A aplicação `app.py` foi estruturada em três abas funcionais (Tabs) com foco em *User Experience (UX)* para profissionais de saúde:

-  **Aba 1: Preditor Analítico (IA)** Interface de simulação. Recebe os inputs médicos em formulários dinâmicos (`st.selectbox`, `st.slider`), empacota os dados em um `DataFrame` em tempo real, passa pelo arquivo `.pkl` e devolve o nível previsto instantaneamente.
-  **Aba 2: Dashboard de Insights Médicos** Integração com `plotly.express` para fornecer gráficos interativos (Pizza, Dispersão e Barras). O carregamento dos dados é otimizado via decorador `@st.cache_data`, evitando recálculos e mantendo a aplicação leve no servidor na nuvem.

-  **Aba 3: Dicionário de Dados** Aba de consulta rápida baseada no material PDF, permitindo que o médico entenda as escalas numéricas utilizadas nos formulários (Ex: o que significa a escala 0 a 3 de FAF).
-

6. Conclusão

O sistema atendeu plenamente aos requisitos da Fase 4 da Pós-Graduação, unindo análise exploratória, engenharia de dados, modelagem matemática rigorosa e engenharia de software (deploy).